

2022년 데이터 분석 청년인재 양성사업 일경험수련 결과보고서

감귤 생산량 추정을 위한 나무 상태 기반 감귤 착과량 예측 모델 구축

2022.01.31

Y220224	고수연
---------	-----

식품안전정보원

목 차

I . 업무수행 내용	03
1. 수행 개요	03
1.1 프로젝트명	03
2.2 수행 목표	03
3.3 문제	03
4.4 업무 활용방안	03
2. 수행 방법	03
2.1 데이터 설명	03
2.2 데이터 탐색	04
2.3 모델 설명	06
3. 수행 결과	07
3.1 데이터 전처리	07
3.2 모델 구축	07
3.3 예측 결과	08
4. 기대효과	09
II . 기타 수행내용	10
1. Decision Tree Regressior	10
2. Random Forest	11
III . 부록	11
1. 상세 코드	11
2. 참고 자료	12

I. 업무수행 내용

1. 수행 개요

1.1 프로젝트명

- ☐ 감귤 착과량 예측 모델 구축

1.2 수행 목표

- ☐ 감귤의 생산량에 큰 영향을 미치는 감귤 착과량¹⁾을 예측

1.3 문제

- ☐ 식품안전정보원은 매년 식품 등의 생산활동 실태를 파악하여 식품 관련 정책 수립에 활용할 수 있도록 조사 정리하고 있음
- ☐ 하지만 생산량 추정을 위해 조사해야 하는 면적은 방대하고 인력은 한정되어 있으며 관측조사의 경우 개인의 경험 및 판단에 의존하기 때문에 데이터 수집이 일관적이지 않을 가능성 또한 존재함

1.4 업무 활용방안

- ☐ 높은 정확률의 생산량 예측 모델을 구축하여 부족한 조사 인력을 대체하고 불필요한 업무 중복을 방지할 수 있음
- ☐ 나아가 다양한 농축산 생산량 예측 모델 매뉴얼을 구축하여 생산량 조사에 관한 인력 운영 효율화 방안을 수립할 수 있음

2. 수행 방법

2.1 데이터 설명

가. 수목 규격 정보

1) 수고

- 지표면에서 수관의 정상까지의 수직거리
- 단위: m
- 계산: $\{(\text{초두부}^2)^{\text{각도}} \% - \text{근원부}^3)^{\text{각도}} \% \} / 100 \times \text{수평거리}$


2) 수관폭

- 수관의 직경
- 단위: m
- 계산: $\text{가로수관폭}(a)/2 \times \text{세포수관폭}(b)/2 \times \pi$

1) 열매가 달리는 양(열매수/꽃수*100)

2) 묘목의 끝

3) 뿌리와 줄기가 서로 분기되는 지면



[그림2-1] 수목의 규격 명칭

나. 과실 형성에 영향을 미치는 요소

1) 새순

- ☐ 새로 돌아 나온 싹으로 꽃과 열매와 같이 양분을 소모하는 수용기관임
- ☐ 따라서 새순과 열매는 양분경쟁을 하게 되어 과실 형성 시기의 새순이 많을 경우 착과량이 적어지게 됨

2) 엽록소

- ☐ 광합성의 핵심 분자로 빛에너지를 흡수하는 안테나 역할을 하는 색소
- ☐ 엽록소가 적게 생성되면 햇빛을 충분히 받지 못해 속이 잘 익지 않을 수 있음
- ☐ 엽록소가 많이 생성되면 맛은 좋지만 껍질에 녹색이 많이 남아 있게 됨

2.2 데이터 탐색

가. 데이터 목록

[표2-1] 데이터 칼럼 리스트

칼럼명	칼럼 설명	형식	예시
ID	과수나무 고유 ID	str	TRAIN_0000
착과량	열매가 달리는 양	int	692
수고	지표에서 수목 정상부까지의 수직거리 (cm)	int	275.0
수관폭1	수관폭 min (cm)	int	287.0

수관폭2	수관폭 max (cm)	int	292.0
수관폭평균	수관폭1과 수관폭2의 평균 (cm)	int	289.5
새순	2022년 09월 01일 ~ 2022년 11월 28일에 일별 측정된 새순 데이터 89개	int	2.8, 2.8, 2.7 ...
엽록소	2022년 09월 01일 ~ 2022년 11월 28일에 일별 측정된 엽록소 데이터 89개	int	78.33650360, ...

나. EDA 및 시각화

1) EDA

[표2-2] 데이터 통계량

	착과량 (int)	수고 (m)	수관폭1 (min)	수관폭1 (max)	수관폭 평균	2022-09-01 새순	2022-09-01 엽록소*
개수	2207.00	2207.00	2207.00	2207.00	2207.00	2207.00	2207.00
평균*	406.22	243.73	315.19	358.82	337.01	3.77	76.90
분산*	218.98	35.89	66.33	68.86	64.86	0.77	4.08
최소	1.00	95.00	95.00	123.00	109.00	2.30	63.03
1분위수	221.00	223.00	271.50	313.50	294.00	3.10	74.08
중위수	404.00	243.00	316.00	364.00	340.50	3.80	76.86
3분위수	593.500	267.00	361.00	402.00	380.00	4.40	79.67
최대	799.00	381.00	559.00	584.00	571.50	5.30	91.01

* 소수점 아래 셋째 자리에서 반올림

- ☐ 중복 데이터 및 결측 데이터 없음
☐ 데이터 분포가 고르다는 특징이 있음


2) 상관분석

[표2-3] 데이터 상관분석 결과

	착과량 (int)	수고 (m)	수관폭1 (min)	수관폭2 (max)	수관폭 평균	2022-09-01 새순	2022-09-01 엽록소
착과량 (int)	1.000000	0.007002	0.021279	0.037168	0.030611	-0.980777	-0.005808
수고 (m)	0.007002	1.000000	0.456394	0.484295	0.490456	-0.004329	0.021110
수관폭1 (min)	0.021279	0.456394	1.000000	0.841330	0.957948	-0.017625	0.003154
수관폭2 (max)	0.037168	0.484295	0.841330	1.000000	0.961049	-0.032941	-0.005632
수관폭 평균	0.030611	0.490456	0.957948	0.961049	1.000000	-0.026499	-0.001377
22-09-01 새순	-0.980777	-0.004329	-0.017625	-0.032941	-0.026499	1.000000	0.007344
22-09-01 엽록소	-0.005808	0.021110	0.003154	-0.005632	-0.001377	0.007344	1.000000


- ☐ 착과량과 새순은 매우 높은 음의 상관관계를 보임
☐ 착과량과 엽록소와는 큰 연관성이 없음

3) 시각화



[그림2-2] 새순과 엽록소 각각의 분포

- 새순과 엽록소 모두 시간이 지날수록 줄어드는 양상을 보임



[그림2-2] 새순과 엽록소의 분포

- 특징에 따라 그룹이 형성되는 양상을 보임
- 이는 새순 데이터로 추정이 가능하지만 새로운 feature가 추가로 필요함
- 새순 5.0은 착과량 0~100 사이의 값을 가짐
- 새순 5.0의 데이터들이 착과량 mean value를 갖게 됨

2.3 모델 설명

가. AutoML을 이용한 양상불 기법

1) AutoML

- 머신러닝을 위한 고급 모델 구축을 자동화해주는 기술

- 수많은 머신러닝 알고리즘 중에서 내가 하려는 분석에 어떤 기법이 최적의 결과를 도출하는지 계산하여 처리함

2) MLJAR: AutoML Toolkit

- 주요 AutoML 툴킷 중 하나인 MLJAR-AutoML의 Compete 모드 사용
- Compete 모드는 기계학습에 사용되며 수행시간이 다소 길지만 사용 알고리즘이 다양하여 최적의 모델을 구축하는데 용이

나. 모델 평가 지표

1) MAE(Mean Absolute Error)

$$MAE = \frac{\sum_{i=1}^N |y_i - \hat{y}_i|}{N}$$

[그림2-3] MAE 계산 수식

- 평균 제곱 오차.
- 실제 정답 값과 예측값의 차이를 제공한 뒤 평균을 구하는 방법으로 ERROR의 절대값 그 자체를 나타내기 때문에 값이 낮을수록 좋음

3. 수행 결과

3.1 데이터 전처리

가. feature 추가

- 새순 데이터와 엽록 데이터의 평균, 표준편차, 증감폭 데이터 칼럼을 추가

```
# 평균
train_df["엽록소mean"] = train_df.filter(regex="엽록소").mean(axis=1)
# 표준편차
train_df["엽록소std"] = train_df.filter(regex="엽록소").std(axis=1)
# 증감폭
train_df["엽록소diff"] = train_df["2022-11-28 엽록소"] - train_df["2022-09-01 엽록소"]

# 이후 동일
train_df["새순mean"] = train_df.filter(regex="새순").mean(axis=1)
train_df["새순std"] = train_df.filter(regex="새순").std(axis=1)
train_df["새순diff"] = train_df["2022-11-28 새순"] - train_df["2022-09-01 새순"]
```

3.2 모델 구축

가. 기본 파라미터 설정

- os.environ["OMP_NUM_THREADS"] = '4'
- mode="Compete"
- eval_metric='mae'


나. 모델 성능

```
AutoML directory: AutoML_1
The task is regression with evaluation metric mae
AutoML will use algorithms: ['Decision Tree', 'Linear',
'Random Forest', 'Extra Trees', 'LightGBM', 'Xgboost',
'CatBoost', 'Neural Network', 'Nearest Neighbors']
AutoML will stack models
AutoML will ensemble available models
AutoML steps: ['adjust_validation', 'simple_algorithms',
'default_algorithms', 'not_so_random', 'golden_feature
s', 'kmeans_features', 'insert_random_feature', 'feature
s_selection', 'hill_climbing_1', 'hill_climbing_2', 'boo
st_on_errors', 'ensemble', 'stack', 'ensemble_stacked']
* Step adjust_validation will try to check up to 1 model
Ensemble_Stacked mae 28.992234 trained in 35.69 seconds
AutoML fit time: 3652.87 seconds
AutoML best model: Ensemble_Stacked
```

[그림3-1] 모델 구축

- ☐ best model로 Ensemble_Stacked이 선정됨
- ☐ MAE 값이 28.992234으로 비교 모델 중 가장 낮은 수치를 보임

3.2 예측 결과



[그림3-1] 예측값 비교

	ID	작과량(int)
0	TEST_0000	247.931299
1	TEST_0001	753.186495
2	TEST_0002	154.115381
3	TEST_0003	449.842567
4	TEST_0004	685.512154
...	...	...
2203	TEST_2203	752.970051
2204	TEST_2204	334.372493
2205	TEST_2205	357.969839
2206	TEST_2206	249.377139
2207	TEST_2207	73.165167
2208 rows × 2 columns		

[그림3-2] 예측 결과

- ☐ 검증데이터 오차율: 0.0722691661
- ☐ 실제 데이터 오차율: 0.0723660444
- ☐ 매우 높은 수치의 정확률을 보임

4. 기대 효과

- ☐ 작과량 예상값을 통해 감귤 생산량을 예측할 수 있음 이를 통해 현장 조사의 필요성이 줄어들고 부족한 조사 인력을 충당할 수 있음
- ☐ 생산 예측량을 식품업체와 유통업체에게 전달하여 생산 및 유통량을 조절할 수 있도록 도움을 줌
- ☐ 예상 생산량과 신고량이 차이가 많이나는 업소를 예의주시하며 감찰 파견 시 우선 파견 대상으로 선정하도록 함
- ☐ 농축산 생산량 예측 모델 매뉴얼을 제작하여 생산량 조사에 관한 인력 운영 효율화 방안을 수립할 수 있음

II. 기타 업무수행 내용

1. Decision Tree Regressor

1.1 데이터 전처리

가. 스케일링

```
from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler()
x_train = scaler.fit_transform(x_train)
x_test = scaler.transform(x_test)
```

나. 검증 데이터 분리

```
from sklearn.model_selection import train_test_split
X_tr, X_val, y_tr, y_val = train_test_split(x_train, y_train, test_size=0.15, random_state=2021)
X_tr.shape, X_val.shape, y_tr.shape, y_val.shape
```

1.2 모델 구축

가. 모델 학습

```
from sklearn.tree import DecisionTreeRegressor
model1 = DecisionTreeRegressor()
model1.fit(X_tr, y_tr)
```

나. 모델 검증

```
from sklearn.metrics import mean_squared_error, r2_score
def rmse(y, y_pred):
    return np.sqrt(mean_squared_error(y, y_pred))
print("R2 : " + str(r2_score(y_val, pred)))
print("RMSE : " + str(rmse(y_val, pred)))
```

다. 모델 성능

```
R2 : 0.9528368208864445
RMSE : 46.93593429037973
```

[그림] 모델 평가 지표

□ MAE 값이 약 46.936으로 프로젝트에 사용한 모델보다 높은 수치를 보여 기각함

2. Random Forest

2.1 데이터 전처리

가. 시계열 데이터 전처리

```
saesoon = list(train_raw_df.columns[6:95]) # 시계열
yuprokso = list(train_raw_df.columns[95:]) # 시계열
train_melt = train_raw_df.melt(id_vars=['ID']+y_var+id_var, value_vars=saesoon+yuprokso)
test_melt = test_raw_df.melt(id_vars=['ID']+id_var, value_vars=saesoon+yuprokso)
```

나. 검증 데이터 분리

```
from sklearn.model_selection import train_test_split
X_tr, X_val, y_tr, y_val = train_test_split(x_train, y_train, test_size=0.15, random_state=2021)
X_tr.shape, X_val.shape, y_tr.shape, y_val.shape
```

2.2 모델 구축

가. 모델 학습

```
from sklearn.ensemble import RandomForestRegressor
model12 = RandomForestRegressor(max_depth=5, random_state=1740, n_estimators=200)
model11.fit(X_tr, y_tr)
```

나. 모델 성능

- ☐ max depth가 5였을 때 가장 좋은 성능을 보였지만 결과에 큰 영향을 주지 못 하여 기각함

Ⅲ. 부록

1. 상세 코드

```
import pandas as pd
import numpy as np
import random
import os

# pip install mljar-supervised
```

```

from supervised.automl import AutoML
def seed_everything(seed):
    random.seed(seed)
    os.environ['PYTHONHASHSEED'] = str(seed)
    np.random.seed(seed)
seed_everything(42) # Seed 고정

import matplotlib
from matplotlib import font_manager, rc
import matplotlib.pyplot as plt
font_name = font_manager.FontProperties(fname="c:/Windows/Fonts/malgun.ttf")
.get_name()
rc('font', family=font_name)

matplotlib.rcParams['axes.unicode_minus'] = False
train_df = pd.read_csv('data/train.csv')
test_df = pd.read_csv('data/test.csv')
train_df.describe()
sns.scatterplot(data=train_df.filter(regex="업록소").iloc[15].values)
train_df["업록소mean"] = train_df.filter(regex="업록소").mean(axis=1)
train_df["업록소std"] = train_df.filter(regex="업록소").std(axis=1)
train_df["업록소diff"] = train_df["2022-11-28 업록소"] - train_df["2022-09-01 업록소"]
train_df["새순mean"] = train_df.filter(regex="새순").mean(axis=1)
train_df["새순std"] = train_df.filter(regex="새순").std(axis=1)
train_df["새순diff"] = train_df["2022-11-28 새순"] - train_df["2022-09-01 새순"]
test_df["업록소mean"] = test_df.filter(regex="업록소").mean(axis=1)
test_df["업록소std"] = test_df.filter(regex="업록소").std(axis=1)
test_df["업록소diff"] = test_df["2022-11-28 업록소"] - test_df["2022-09-01 업록소"]
test_df["새순mean"] = test_df.filter(regex="새순").mean(axis=1)
test_df["새순std"] = test_df.filter(regex="새순").std(axis=1)
test_df["새순diff"] = test_df["2022-11-28 새순"] - test_df["2022-09-01 새순"]
X = train_df.iloc[:, 2:]
y = train_df.iloc[:, 1]
automl = AutoML(mode="Compete", eval_metric='mae')
os.environ["OMP_NUM_THREADS"] = '4'
automl.fit(X, y)
pred = automl.predict(test_df.iloc[:, 1:])

```

2. 참고 자료

- ☐ 올해산 노지감귤 생산예상량 45만7,000톤 내외 - 컬처제주
<http://www.culturejeju.kr/news/articleView.html?idxno=41164>
- ☐ 착화량과 착과율(생육정보) - 농촌 진흥원
https://fruit.nihhs.go.kr/citrus/grwhInfo_FlwrFrst.do
- ☐ 제주감귤연합회 감귤 재배현황(재배면적, 생산량, 농가수, 수입현황)

<http://jejugamgyul.or.kr/story/story06.asp?scrID=0000000133&pageNum=5&subNum=5&ssubNum=1>

☐ mljar-supervised

<https://github.com/mljar/mljar-supervised>