

2022년 데이터 분석 청년인재 양성사업 일경험수련 결과보고서

한우 유전자원 보호 및 종자 개발 산업 진흥을 위한 유전정보를 통한 품종 분류 모델 구축 및 비교

2022.01.31

Y220224	고수연
---------	-----

식품안전정보원

목 차

1. 수행 개요	03
1.1 프로젝트명	03
1.2 수행 목표	03
1.3 필요성	03
1.4 업무 활용 방안	04
2. 수행 방법	04
2.1 데이터 탐색	04
2.2 모델 선정	07
2.3 전체 프로세스	07
3. 수행 결과	10
3.1 예측 수치	10
4. 기대효과	10

1. 수행 개요

1.1 프로젝트명

- 한우 유전자원 보호 및 종자 개발 산업 진흥을 위한 유전정보를 통한 품종 분류 모델 구축 및 비교

1.2 수행 목표

- 염색체상의 단일염기다형성(SNP)을 통해 생산품종을 분류하는 모델 제작

1.3 필요성

- 한우 유전자원의 가치
 - 유전자원은 현재 인류에게 실질적 가치가 있는 자원뿐 아니라 현재 이용 가치는 없지만, 미래에 이용 가능한 잠재력이 있는 자원을 의미함¹⁾
 - 기록에 따르면 한반도에서 가축화된 소는 약 25종에 달했으나, 일제강점기에 한우의 모색을 황갈색으로 규정하며 적색(황색) 한우를 제외한 특이 모색을 갖는 흑우, 칙소, 백우 등은 사실상 멸종위기 상태임²⁾
 - 그러나 황갈색의 모색은 열성 유전이기에 종자 개량에 적합하지 않고, 단일품종이다 보니 소비자의 다양한 요구를 반영하는 것도 한계가 있으나, 우성형질인 흑우는 상대적으로 개량이 쉽고 개량의 여지가 많음³⁾
 - 축산업은 평균적으로 국가 경제에서는 4~5%, 농업생산액으로는 30% 정도를 차지하며, 특히 고급육에 대한 수요는 증가추세에 있으나, 한우 품종 다양성의 중요성은 90년대에 들어서야 대두되기 시작⁴⁾
- 한우 품종 분류 모델의 필요성
 - 칙소의 경우 까만 얼룩무늬 모색으로 구분하는데 명확한 기준이 없어 농가에서 출하할 때 칙소가 잡우 또는 이모색으로 분류되는 경우가 많아 농가의 손해를 가져오고 있음⁵⁾
 - 이에 2019년 염색체상의 단일염기다형성(SNP)을 통해 품종을 분류하는 모델이 고안되었음⁶⁾
 - 현재 한우의 비한우의 분류는 약 90개의 단일염기다형성(SNP) 비교를 통해 이루어지며, 한우 사이의 품종 분류를 위해서는 21개의 염기 마커가 필요한데, 더 적은 형질로 분류가 가능해지면 시간과 비용 측면에서 경제성이 더 향상됨⁷⁾

1) 한지영, 유전자원의 생명공학적 이용 및 규제, 한국 법제 연구원, 2016

2) 김황수진, 토종 소 '칙소·흑우'를 지켜라!., 한국농정, 2011.08.20.

3) 옥미영, <http://www.farminsight.net/news/articleView.html?idxno=9541>, Farminsight, 2022.09.27.

4) 김승창 외, 단일염기다형성 마커를 이용한 칙소 품종의 식별, 농촌진흥청 국립축산과학원 가축유전자원센터, 2022

5) 농촌진흥청, 재래 품종 '칙소', 판별 기술 개발, 대한민국 정책 브리핑, 2019

6) 농촌진흥청, 재래 품종 '칙소', 판별 기술 개발, 대한민국 정책 브리핑, 2019

7) 농촌진흥청, 재래 품종 '칙소', 판별 기술 개발, 대한민국 정책 브리핑, 2019

1.4 업무 활용 방안

- 더 적은 단일염기다형성(SNP)을 바탕으로 한우 생산품종을 분류할 수 있음

2. 수행 방법

2.1 데이터 탐색

- 분석 데이터 목록

1) train data 컬럼표







컬럼	컬럼 설명	형식
ID	개체 번호	str
MOTHER	개체의 모계 고유 번호	int
FATHER	개체의 가계 고유 번호	int
GENDER	개체의 성별	int
TRAIT	개체의 표현형 정보	int
SNP01	유전인자 BTA-19852-no-rs	int
...		
SNP15	유전인자 BovineHD1000000224	int
CLASS	개체의 고유 품종	str


- 21개의 열, 262개의 행으로 구성되어있음
- 각 컬럼은 모두 결측값이 없는 상태
- MOTHER, FATHER 컬럼은 모든 데이터의 값이 같아 의미 없는 컬럼이었음
- 한우-수입우 판별 유전자 분석기법(2008)을 참고하여 유전자 마커인 SNP 데이터만을 사용하기로 함⁸⁾
- X값: SNP01~SNP15
- Y값: CLASS


8) 한우.수입우 판별 유전자 분석기법 - 이동형 진단장치(2008).
<https://www.nongsaro.go.kr/portal/hightech/htmlfile/A01090801/A01090801.pdf>

□ EDA

1) 2차원 데이터 분포







2.2 모델 선정

- ☐ 로지스틱 회귀
 - 데이터에 눈에 띄는 이상치가 없음
 - 분류 경계가 단순한 형태가 많음
 - 테스트 데이터와 트레인 데이터를 비교했을 때, 데이터 분포의 차이가 적었음
 - 빠르게 구현 가능함
- ☐ 랜덤 포레스트 모델
 - 조정할 수 있는 하이퍼파라미터가 많다
 - 과적합에 강하다
 - 분류 모델로 널리 쓰인다
 - 빠르게 구현 가능함

2.3 전체 프로세스

- ☐ 전체 코드

1.사전준비
<pre>import pandas as pd from sklearn.preprocessing import LabelEncoder from sklearn.linear_model import LogisticRegression import numpy as np</pre>
2. 데이터 불러오기 및 정제
<pre>#트레인 데이터 로드 df = pd.read_csv('train.csv') #트레인 데이터 분석 df.describe() df.info() #트레인 데이터 전처리 x_train = df.drop(['class', 'id'], axis=1)</pre>

```

y_train = df.iloc[:, 0]
#트레인 Y 원핫인코딩
le = LabelEncoder()
le.fit(y_train)
print(le.classes_) #['A' 'B' 'C']
y_labels = le.classes_
y_train = le.transform(y_train)
#트레인 데이터 내부의 기호를 숫자로 변환하기
x_train = x_train.replace('A A', '0', regex=True)
x_train = x_train.replace('(.*)A C(.*)', '1', regex=True)
x_train = x_train.replace('(.*)A G(.*)', '2', regex=True)
x_train = x_train.replace('(.*)C A(.*)', '3', regex=True)
x_train = x_train.replace('(.*)C C(.*)', '4', regex=True)
x_train = x_train.replace('(.*)G A(.*)', '5', regex=True)
x_train = x_train.replace('(.*)G G(.*)', '6', regex=True)
#테스트 데이터 로드
df = pd.read_csv('test.csv')
#테스트 데이터 분석
df.describe()
df.info()
#테스트 데이터 전처리
x_test = df.iloc[:, 4:]
#테스트 데이터 내부의 기호를 숫자로 변환하기
x_testint = x_test.replace('A A', '0', regex=True)
x_testint = x_testint.replace('(.*)A C(.*)', '1', regex=True)
x_testint = x_testint.replace('(.*)A G(.*)', '2', regex=True)
x_testint = x_testint.replace('(.*)C A(.*)', '3', regex=True)
x_testint = x_testint.replace('(.*)C C(.*)', '4', regex=True)
x_testint = x_testint.replace('(.*)G A(.*)', '5', regex=True)
x_testint = x_testint.replace('(.*)G G(.*)', '6', regex=True)

```

3. 로지스틱 회귀 모델 구축

```

#로지스틱 모델 생성
model = LogisticRegression()
#모델 학습
model.fit(x_train, y_train)
#모델 검증
print(model.score(x_train, y_train))
#예측

```



```

predict = model.predict(x_testint)
predict = pd.DataFrame(predict, columns = ['class'])
predict.astype('string')
predict = predict.replace(0, 'A', regex=True)
predict = predict.replace(1, 'B', regex=True)
predict = predict.replace(2, 'C', regex=True)
predict.to_csv(path_or_buf='logistic.csv')

```

4. 랜덤 포레스트 하이퍼 파라미터 조정

```

#필요 모듈 임포트
#그리드 서치 사용
from sklearn.model_selection import GridSearchCV
from sklearn.ensemble import RandomForestClassifier
# 후보군 임의 설정
param_grid = {
    'n_estimators' : [100, 150, 200, 250, 300],
    'max_depth' : [None, 3, 6, 9, 10],
    'max_features' : ['sqrt', 'log2']
}
model_rf = RandomForestClassifier(random_state = 100)
grid_search = GridSearchCV(estimator = model_rf,
                           param_grid = param_grid,
                           scoring = 'accuracy',)
grid_search.fit(x_train, y_train)
grid_search.best_params_

```

4. 랜덤 포레스트 모델 구축

```

#랜덤포레스트
model_rf = RandomForestClassifier() # 모델을 객체에 할당
model_rf.fit(x_train, y_train) # 모델 학습
#예측
predict_r = model_rf.predict(x_testint)
predict_r = pd.DataFrame(predict_r, columns = ['class'])
predict_r = predict_r.replace(0, 'A', regex=True)
predict_r = predict_r.replace(1, 'B', regex=True)
predict_r = predict_r.replace(2, 'C', regex=True)
predict_r.to_csv(path_or_buf='random.csv')

```

- 랜덤포레스트의 하이퍼 파라미터는 그리드 서치를 이용하여 추정

3. 수행 결과

3.1 예측 수치

- ☐ 학습 완료된 모델에 테스트 데이터를 넣어 예측한 결과, 로지스틱 회귀 모델의 예측 정확도는 0.9814285714, 랜덤 포레스트의 예측정확도는 0.9622367466로 관측
- ☐ 로지스틱 회귀 모델의 정확도가 더 좋았던 이유는 다음으로 추정
 - 데이터에 이상치가 없었음
 - 테스트 데이터와 트레인 데이터의 데이터 분포가 비슷함
 - 랜덤 포레스트의 하이퍼 파라미터가 최적의 파라미터가 아니었음

4. 기대효과

- ☐ 유전정보를 통해 한우 품종을 자동 분류하여 국내 스마트 축산 시장과 고품질 유지에 기여
- ☐ 종자별 유전적 특징을 고려해 적합한 사료·사육 환경을 적용하는 스마트 축산 시스템 보급화
- ☐ 한우 유전자원 보호 및 산업적 활용 도모에 기여